

# REDES NEURAIS SEM PESO

Utilizando de redes neurais sem peso para predição de cargas de trabalho em clusters

Stanley C. de Sousa

PESC/COPPE - UFRJ

10 de julho de 2020

# Roteiro

- 1 Contexto
- 2 Dados
- 3 Modelagem
  - Pré-processamento
  - Codificação
- 4 Modelos e Parâmetros
- 5 Resultados
- 6 Conclusão

# Contexto

- Clusters e Computação em Nuvem
- Alta Disponibilidade e Escalabilidade
- Auto escalonamento: Reativo x Pró-Ativo
- Predição, Aprendizagem de Máquina, Regressão
- Exemplo

# Dados

Logs de requisições HTTP disponíveis em:

`ftp://ita.ee.lbl.gov/html/contrib/NASA-HTTP.html`

Os logs contém uma requisição por linha conforme exemplo a seguir:

`kgtyk4.kj.yamagata-u.ac.jp - - [01/Aug/1995:00:00:17 -0400] "GET / HTTP/1.0" 200 7280`

Cada linha contém os seguintes dados, em ordem:

- Hostname (endereço do solicitante)
- Timestamp com resolução de segundo
- Requisição (ação e recurso solicitado)
- Código HTTP de estado da resposta
- Tamanho da resposta em bytes


# Pré-processamento: Extração de dados

Dados de 2 meses foram agrupados em janelas 1, 5, 15, 30 e 60 minutos. Etapas do processamento dos arquivos brutos:

- Extração do timestamp de cada linha do log
- Agregação dos tempos de acordo com as diferentes janelas, contando as ocorrências
- Conversão do timestamp para o padrão ISO
- Escrita dos registros agregados em um novo arquivo

Foi gerado um arquivo para cada janela de tempo.


# Pré-processamento: Visualização da série (janela de 60 minutos)



# Codificação

Comportamento periódico. Caputar variações intra-dia e intra-semana em um número inteiro para utilização no termômetro:

1995-07-02T07:32:40



Data codificada:44800

# Modelos e Parâmetros

Utilizamos a janela de 30 minutos para explorarmos os parâmetros dos seguintes modelos:

- Regression WiSARD(ReW)
- ClusRegression WiSARD(CReW)
- KNN (K Nearest Neighbors)
- Linear SVM (Support Vector Machine)

	AddressSize	Mean	RMSE
ReW:	10	SimpleMean	552.525±0.000
	20	SimpleMean	580.119±0.000
	10	GeometricMean	553.381±0.061




# Modelos e Parâmetros

CReW:	AddressSize	Threshold	Limit	RMSE
	5	0	0	585.374±0.000
	30	0	0	555.884±0.000
	10	5	75	547.641±1.637

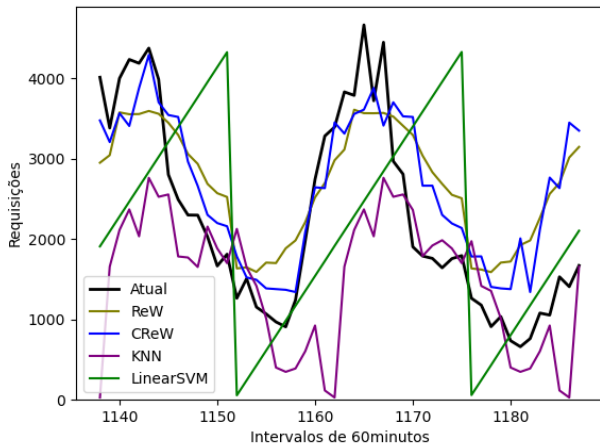
KNN:	Neighbors	Weights	Power	RMSE
	5	Distance	1	570.973±0.000
	5	Uniform	2	522.033±0.000
	10	Uniform	2	748.078±0.000

SVM:	Epsilon	Tolerance	RMSE
	0.5	0.01	746.812±0.000
	2.0	0.0001	611.198±0.000
	3.0	0.0001	611.592±0.000

# Resultados: Requisições em intervalos de 5 minutos



# Resultados: Requisições em intervalos de 60 minutos



# Resultados: Acurácia da predição (RMSE)

Neste trabalho a CReW apresentou tendência em superestimar o valor de sua predição em períodos de variações bruscas, apresentando inércia apenas para descida da curva. No intervalo de menor frequência a CReW se ajustou bem à curva base.

Janela	ReW(10, SimpleMean)	CReW(10, 5 75)	KNN(5, Uniform, 2)	LinearSVM(2, 000.1)
1min	23.714±0.193	23.375±0.070	24.955±0.000	28.954±0.000
5min	103.219±0.204	101.735±0.059	107.864±0.000	130.038±0.000
15min	291.730±1.385	289.226±0.799	330.338±0.000	376.280±0.000
30min	560.319±0.000	548.575±2.920	748.078±0.000	747.082±0.000
60min	1024.333±0.000	980.816±3.777	1479.846±0.000	1491.327±0.000

# Resultados: Tempos

A tabela abaixo apresenta os tempos em segundos (treinamento / predição) de cada modelo.

Janela	ReW	CReW	KNN	LinearSVM
1min	0.110 / 0.112	7.263 / 3.788	0.086 / 0.908	0.025 / 0.010
5min	0.023 / 0.024	1.499 / 0.810	0.011 / 0.184	0.006 / 0.002
15min	0.008 / 0.008	0.499 / 0.272	0.004 / 0.064	0.002 / 0.001
30min	0.004 / 0.004	0.242 / 0.006	0.003 / 0.033	0.001 / 0.000
60min	0.002 / 0.002	0.115 / 0.067	0.002 / 0.017	0.001 / 0.000

# Conclusão

Para realizarmos uma avaliação mais consistente, incluímos os resultados apresentado por Kirchoff et al. 2019 (Apreliminary study of machine learning workload prediction techniques for cloud applications) onde o mesmo dataset foi utilizado para os seguintes modelos:

- Multi Layer Perceptron(MLP)
- Gated Recurrent Unit(GRU)
- Auto Regressive Integrated Moving Average(ARIMA)

Janela	CReW	KNN	LinSVR	MLP	GRU	ARIMA
1min	23.375	24.955	28.954	16.26	16.51	14.27
5min	101.735	107.864	130.038	54.34	53.04	47.86
15min	289.226	330.338	376.280	136.36	132	135.08
30min	548.575	748.078	747.082	249.55	242.86	237.73
60min	980.816	1479.846	1491.327	544.08	521.66	493.90

# Conclusão

Neste trabalho foi utilizado uma série não-estacionária, neste contexto, a CReW obteve melhor acurácia em comparação com técnicas simples de regressão. Entretanto, modelos autoregressivos ou que abordarm o problema de dissipação de gradiente apresentaram resultados melhores.

Em trabalhos futuros podemos buscar verificar se a observada dificuldade da CReW em ajustar para baixo a predição, diante de variações alta frequencia, se confirma e quais são os fatores que mais influenciam este corportamento.